phase2a

January 11, 2023

1 TBD - etap 2a

- 1.0.1 Michał Kopyt, Rafał Kulus, Adrian Prorok
- 1.1 Wczytanie danych

```
[1]: pip install googledrivedownloader
```

```
Requirement already satisfied: googledrivedownloader in /opt/conda/lib/python3.10/site-packages (0.4)
Note: you may need to restart the kernel to use updated packages.
```

1.2 Podłączenie do sesji Spark

```
[3]: from pyspark.sql import SparkSession

spark = SparkSession \
.builder \
.config("spark.executor.instances", "1")\
.config('spark.driver.memory','1g')\
.config('spark.executor.memory', '1g') \
.getOrCreate()
```

1.3 Dostęp do danych

```
[4]: import os
    user_name = 'jovyan'
    # ścieżka dostępu do pliku
    csv_path = 'file:///home/jovyan/data/2020/survey_results_public.csv'
    df = spark.read.csv(csv_path, inferSchema=True, header="true", nullValue='NA', useranValue='NA', emptyValue='NA')
```

1.4 a) Ile jest unikalnych odpowiedzi w zapytaniu o poziom wykształcenia (EdLevel)?

```
[5]: df_ed_level = df.select(df.EdLevel).distinct()

print(f'Liczba unikalnych odpowiedzi w zapytaniu o poziom wyksztalcenia:

→{df_ed_level.count()}')
```

Liczba unikalnych odpowiedzi w zapytaniu o poziom wyksztalcenia: 10

1.5 b) Podaj średnią liczbę godzin przepracowywanych przez respondentów pogrupowanych ze względu na kraj.

```
[6]: df.groupBy("Country").avg("WorkWeekHrs").show()
```

```
Country | avg(WorkWeekHrs) |
        ----+
       Côte d'Ivoire
                                 32.01
           Paraguay|
                               29.875
|The former Yugosl...|
                               39.5
              Yemen
                                 40.0
            Senegal | 34.285714285714285 |
             Sweden | 40.7496062992126 |
  Hong Kong (S.A.R.) | 42.298507462686565 |
   Philippines | 37.32920792079208 |
             Eritrea|
                                 null
           Singapore | 40.25684931506849 |
           Malaysia | 39.255639097744364 |
             Turkey | 43.77202643171806 |
               Iraq | 49.07142857142857 |
            Germany | 40.27298744460857 |
         Afghanistan|
                                 46.5
                                 44.0|
            Cambodia|
              Jordan | 45.806451612903224 |
           Maldives
                                 47.31
```

```
only showing top 20 rows
```

1.6 c) Narysuj wykres słupkowy popularności wykorzystywanych baz danych przez profesjonalnych programistów. Skorzystaj z funkcji split i posexplode.

```
[7]: df_databases = df.select("DatabaseWorkedWith").filter("DatabaseWorkedWith is⊔

not NULL")

df_databases.show()
```

```
+----+
 DatabaseWorkedWith|
+----+
|Elasticsearch; Mic...|
|MySQL;PostgreSQL;...|
| MariaDB; MySQL; Redis|
|Microsoft SQL Server|
|Firebase; MongoDB; ... |
|Firebase; Microsof...|
         MySQL;Oracle|
           PostgreSQL|
|Microsoft SQL Ser...|
|Elasticsearch; Mar...|
|MariaDB; Microsoft...|
|IBM DB2; MariaDB; M...|
|Firebase; MariaDB; ... |
    PostgreSQL; SQLite |
               Oracle
           PostgreSQL|
|Elasticsearch; MyS...|
|Microsoft SQL Ser...|
         MySQL; SQLite |
|MongoDB;MySQL;Pos...|
only showing top 20 rows
```

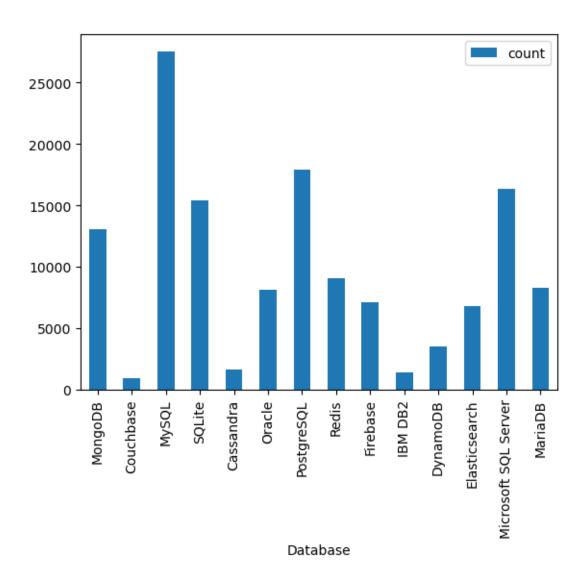
```
+-----+
|Position| Database|
+-----+
```

```
0|
                  Elasticsearch|
        1|Microsoft SQL Server|
        2|
                         Oracle
        0|
                          MySQL|
        1|
                     PostgreSQL|
        2|
                          Redis|
        3|
                         SQLite|
        01
                        MariaDB|
        1|
                          MySQL|
        2|
                          Redis|
        O|Microsoft SQL Server|
        0|
                       Firebase|
        1|
                        MongoDB|
                     PostgreSQL|
        2|
        31
                         SQLite
        0|
                       Firebase
        1|Microsoft SQL Server|
        0|
                          MySQL|
                         Oracle
        1|
        01
                     PostgreSQL|
only showing top 20 rows
```

```
[9]: df_databases_splitted.groupBy("Database").count().toPandas().plot.

spar(x="Database")
```

[9]: <AxesSubplot: xlabel='Database'>



1.7 Przygotowanie modelu do predykcji

Wramach zadania chcemy stworzyć klasyfikator, który będzie przewidywać czy respondent zarabia więcej niż 60000 USD rocznie.

```
LOCATION "{csv_path}"')

spark_df= spark.sql(f'SELECT *, CAST((convertedComp > 60000) AS STRING) AS

⇔compAboveAvg \

FROM {table_name} where convertedComp IS NOT NULL ')
```

```
[11]: from pyspark.ml.feature import StringIndexer, OneHotEncoder, VectorAssembler
      from pyspark.ml import Pipeline
      y = 'compAboveAvg'
      feature_columns = ['OpSys', 'EdLevel', 'MainBranch', 'Country', 'JobSeek', __

    'YearsCode']

      stringindexer_stages = [StringIndexer(inputCol=c, outputCol='stringindexed' + L
       GC).setHandleInvalid("keep") for c in feature_columns]
      stringindexer stages += [StringIndexer(inputCol=y, outputCol='label')]
      onehotencoder_stages = [OneHotEncoder(inputCol='stringindexed_' + c,__
       →outputCol='onehot_' + c) for c in feature_columns]
      extracted_columns = ['onehot_' + c for c in feature_columns]
      vectorassembler_stage = VectorAssembler(inputCols=extracted_columns,_

→outputCol='features')
      final_columns = [y] + feature_columns + extracted_columns + ['features',_
       transformed_df = Pipeline(stages=stringindexer_stages + \
                                onehotencoder_stages + \
                                [vectorassembler_stage]).fit(spark_df).
       ⇔transform(spark_df).select(final_columns)
      training, test = transformed df.randomSplit([0.8, 0.2], seed=1234)
```

1.7.1 Drzewo decyzyjne

```
[12]: # na poczatek wybierzemy drzewo decyzyjne. Nie musimy podawac zadnych parametrow
from pyspark.ml.classification import DecisionTreeClassifier
dt = DecisionTreeClassifier(featuresCol='features', labelCol='label')

simple_model = Pipeline(stages=[dt]).fit(training)

pred_simple = simple_model.transform(test)

# macierz pomytek (confusion matrix)
label_and_pred = pred_simple.select('label', 'prediction')
label_and_pred.groupBy('label', 'prediction').count().toPandas()
```

```
[12]:
                                     label prediction count
                                              1.0
                                                                                                 1.0
                                                                                                                          2259
                         1
                                              0.0
                                                                                                 1.0
                                                                                                                              644
                         2
                                              1.0
                                                                                                0.0
                                                                                                                             831
                         3
                                              0.0
                                                                                                0.0
                                                                                                                          3132
[13]: # Ewaluator
                         from pyspark.ml.evaluation import BinaryClassificationEvaluator
                         evaluator = BinaryClassificationEvaluator(rawPredictionCol="rawPrediction", __
                              →metricName="areaUnderROC")
                         auroc_simple = evaluator.evaluate(pred_simple)
                         from pyspark.ml.evaluation import MulticlassClassificationEvaluator
                         evaluator_m = MulticlassClassificationEvaluator(labelCol="label", __
                               General continuous prediction of the con
                         accuracy = evaluator_m.evaluate(pred_simple)
                         print(f'Drzewo decyzyjne, auroc: {auroc_simple}, accuracy: {accuracy}')
```

Drzewo decyzyjne, auroc: 0.5986083542455158, accuracy: 0.7851733177978445

1.7.2 Dodanie hiperparametrów

```
[14]: # Jakie wartości hiperparametru maxDepth mają być przetestowane:
    from pyspark.ml.tuning import ParamGridBuilder

param_grid = ParamGridBuilder().\
        addGrid(dt.maxDepth, [2,3,4,5,6]).\
        build()

# Walidacja krzyżowa wykonwyana w celu optymalizacji hiperparametrów
from pyspark.ml.tuning import CrossValidator

cv = CrossValidator(estimator=dt, estimatorParamMaps=param_grid,usevaluator=evaluator, numFolds=4)

# Budowa modelu na podstawie danych treningowych
cv_model = cv.fit(training)

cv_model.bestModel
```

[14]: DecisionTreeClassificationModel: uid=DecisionTreeClassifier_5bf042cf4950, depth=2, numNodes=5, numClasses=2, numFeatures=229

1.7.3 Predykcja z nowym modelem

```
[15]: pred_cv = cv_model.transform(test)
      # Confusion matrix
      label_and_pred = pred_cv.select('label', 'prediction')
      label_and_pred.groupBy('label', 'prediction').count().toPandas()
[15]:
        label prediction count
           1.0
                       1.0
                            1816
      1
          0.0
                       1.0
                              345
      2
          1.0
                      0.0 1274
                            3431
      3
          0.0
                       0.0
[16]: auroc_cv = evaluator.evaluate(pred_cv)
      auroc_cv
[16]: 0.6893249307498216
[17]: acc_cv = evaluator_m.evaluate(pred_cv)
      acc_cv
```

[17]: 0.7642004078065832

1.7.4 Klasyfikacja za pomoca Gradient Boosted Trees

```
[18]: from pyspark.ml.classification import GBTClassifier
  gbt = GBTClassifier(labelCol="label", featuresCol="features", maxIter=10)
  model = gbt.fit(training)

auroc_gbt = evaluator.evaluate(model.transform(test))
  acc_gbt = evaluator_m.evaluate(model.transform(test))

print(f'GBT, auroc: {auroc_gbt}, accuracy: {acc_gbt}')
```

GBT, auroc: 0.88280847183369, accuracy: 0.8049810661229245

1.8 d1) Sprawdź czy można bardziej poprawić jakość predykcji dla zadania z tego notatnika: dodając cechy?

Do dodanych wcześniej atrybutów dodaliśmy cechy: NEWOvertime i YearsCodePro

```
onehotencoder_stages = [OneHotEncoder(inputCol='stringindexed_' + c,__
       →outputCol='onehot_' + c) for c in feature_columns]
      extracted_columns = ['onehot_' + c for c in feature_columns]
      vectorassembler stage = VectorAssembler(inputCols=extracted columns,
       ⇔outputCol='features')
      final_columns = [y] + feature_columns + extracted_columns + ['features',__
       transformed_df = Pipeline(stages=stringindexer_stages + \
                                onehotencoder stages + \
                                [vectorassembler_stage]).fit(spark_df).
      stransform(spark_df).select(final_columns)
      training, test = transformed df.randomSplit([0.8, 0.2], seed=1234)
      # Drzewo decyzyjne
      dt = DecisionTreeClassifier(featuresCol='features', labelCol='label')
      simple_model = Pipeline(stages=[dt]).fit(training)
      pred_simple = simple_model.transform(test)
      # macierz pomyłek (confusion matrix)
      label_and_pred = pred_simple.select('label', 'prediction')
      label_and_pred.groupBy('label', 'prediction').count().toPandas()
[19]:
        label prediction count
          1.0
                             2254
                      1.0
      1
          0.0
                      1.0
                             608
      2
          1.0
                      0.0
                             836
          0.0
                      0.0
                            3168
[20]: auroc_simple = evaluator.evaluate(pred_simple)
      accuracy = evaluator_m.evaluate(pred_simple)
      print(f'Drzewo decyzyjne, dodane cechy, auroc: {auroc simple}, accuracy:

√{accuracy}')
     Drzewo decyzyjne, dodane cechy, auroc: 0.6254565540837035, accuracy:
     0.7896883192542965
[21]: # GBT
      model = gbt.fit(training)
      pred_gbt = model.transform(test)
      auroc_gbt = evaluator.evaluate(pred_gbt)
```

stringindexer_stages += [StringIndexer(inputCol=y, outputCol='label')]

```
accuracy_gbt = evaluator_m.evaluate(pred_gbt)
print(f'GBT dodane cechy, auroc: {auroc_gbt}, accuracy: {accuracy_gbt}')
```

GBT dodane cechy, auroc: 0.8959790329658275, accuracy: 0.8204194581998252

Zarówno dla drzewa decyzyjnego jak i GBT, dodanie nowych cech pozwoliło nieznacznie poprawić wartość miar auroc i accuracy.

1.9 d2) Sprawdź czy można bardziej poprawić jakość predykcji dla zadania z tego notatnika: zmieniając model?

Regresja logistyczna, dodane cechy, auroc: 0.8959790329658275, accuracy: 0.8204194581998252

Zmiana modelu na Logistic Regression daje podobne wartości miar auroc i accuracy, co Gradient-Boosted Tree.

1.10 d3) Sprawdź czy można bardziej poprawić jakość predykcji dla zadania z tego notatnika: lepiej dobierając parametry nowego modelu?

[23]: DecisionTreeClassificationModel: uid=DecisionTreeClassifier_5bf042cf4950, depth=2, numNodes=5, numClasses=2, numFeatures=229

Regresja logistyczna, dostrojone parametry, dodane cechy, auroc: 0.6893249307498216, accuracy: 0.8204194581998252

W tym wypadku optymalizacja parametrów nie poprawiła wyników modelu.

```
[25]: spark.stop()
```